

# AULA 15 – AJUSTE DE CURVA (PARTE 2)

Prof. Gustavo Resque  
[gustavoresqueufpa@gmail.com](mailto:gustavoresqueufpa@gmail.com)



LAB  
VIS

# CASO NÃO LINEAR

- Em alguns casos podemos escolher funções não lineares nos parâmetros
  - Por exemplo, para ajustar uma curva exponencial
- Então, para aplicar o método dos quadrados mínimos estudado na aula passada é necessário linearizar o problema
- Por exemplo

$$y \approx \alpha_1 e^{-\alpha_2 x} \Rightarrow z = \ln(y) \approx \ln(\alpha_1) - \alpha_2 x.$$

Se  $a_1 = \ln(\alpha_1)$  e  $a_2 = -\alpha_2 \Rightarrow \ln(y) \approx a_1 - a_2 x = \phi(x)$  que é um problema linear nos parâmetros  $a_1$  e  $a_2$ .

# CASO NÃO LINEAR

- Observações

- Esse ajuste torna a solução não necessariamente ótima
- Portanto, não se pode afirmar que sempre o ajuste da curva encontra a solução ótima para o problema, o que ocorre para a solução linear

# CASO NÃO LINEAR

## ■ Exemplo 6

Suponhamos que num laboratório obtivemos experimentalmente os seguintes valores para  $f(x)$  sobre os pontos  $x_i$ ,  $i = 1, 2, \dots, 8$ :

x	-1.0	-0.7	-0.4	-0.1	0.2	0.5	0.8	1.0
f(x)	36.547	17.264	8.155	3.852	1.820	0.860	0.406	0.246

Fazendo o diagrama de dispersão dos dados acima, obtemos

■ Que nos sugere um ajuste:

$$y \approx \varphi(x) = \alpha_1 e^{-\alpha_2 x}$$




Figura 6.3

# CASO NÃO LINEAR

## ■ Exemplo 6

- A linearização a ser feita é

$$z = \ln(y) \approx \ln(\alpha_1 e^{-\alpha_2 x}) = \ln(\alpha_1) - \alpha_2 x = \phi(x)$$

- Assim, ao invés de ajustar  $y$ , ajustaremos  $z = \ln(y)$  encontrando

$$\phi(x) = a_1 + a_2 x$$

- Onde

- $a_1 = \ln(\alpha_1)$  e
- $a_2 = -\alpha_2$

- Assim

- $g_1(x) = 1$  e
- $g_2(x) = x$

# CASO NÃO LINEAR

## ■ Exemplo 6

■ Temos pois

x	-1	-0.7	-0.4	-0.1	0.2	0.5	0.8	1
z = ln(y)	3.599	2.849	2.099	1.349	0.599	-0.151	-0.901	-1.402

$$\begin{cases} \left[ \sum_{k=1}^8 g_1(x_k)g_1(x_k) \right] a_1 + \left[ \sum_{k=1}^8 g_2(x_k)g_1(x_k) \right] a_2 = \sum_{k=1}^8 z(x_k)g_1(x_k) \\ \left[ \sum_{k=1}^8 g_1(x_k)g_2(x_k) \right] a_1 + \left[ \sum_{k=1}^8 g_2(x_k)g_2(x_k) \right] a_2 = \sum_{k=1}^8 z(x_k)g_2(x_k) \end{cases}$$

$$g_1(x) = 1 \Rightarrow \sum_{k=1}^8 g_1(x_k)g_1(x_k) = \sum_{k=1}^8 1 = a_{11} = 8$$

$$g_2(x) = x \Rightarrow \sum_{k=1}^8 g_2(x_k)g_2(x_k) = \sum_{k=1}^8 x_k^2 = a_{22} = 3.59$$

$$\sum_{k=1}^8 g_1(x_k)g_2(x_k) = \sum_{k=1}^8 1x_k = a_{12} = a_{21} = 0.3$$

$$b_1 = \sum_{k=1}^8 z(x_k)g_1(x_k) = \sum_{k=1}^8 z(x_k) = 8.041$$

$$b_2 = \sum_{k=1}^8 z(x_k)g_2(x_k) = \sum_{k=1}^8 z(x_k) x_k = -8.646$$

# CASO NÃO LINEAR

## ■ Exemplo 6

- Temos pois

x	-1	-0.7	-0.4	-0.1	0.2	0.5	0.8	1
z = ln(y)	3.599	2.849	2.099	1.349	0.599	-0.151	-0.901	-1.402

donde

$$A = \begin{bmatrix} 8 & 0.3 \\ 0.3 & 3.59 \end{bmatrix} \quad b = \begin{bmatrix} 0.041 \\ -8.646 \end{bmatrix}$$

# CASO NÃO LINEAR

## ■ Exemplo 6

■ Temos pois

x	-1	-0.7	-0.4	-0.1	0.2	0.5	0.8	1
z = ln(y)	3.599	2.849	2.099	1.349	0.599	-0.151	-0.901	-1.402

donde

$$A = \begin{bmatrix} 8 & 0.3 \\ 0.3 & 3.59 \end{bmatrix} \quad b = \begin{bmatrix} 0.041 \\ -8.646 \end{bmatrix}$$

e o sistema fica

$$\begin{cases} 8.0a_1 + 0.3a_2 = 8.041 \\ 0.3a_1 + 3.59a_2 = -8.646 \end{cases} \Rightarrow a_1 = 1.099 \text{ e } a_2 = -2.5$$

$$\text{Agora, } \alpha_1 = e^{a_1} \Rightarrow \alpha_1 = e^{1.099} = 3.001$$

$$\alpha_2 = -a_2 \Rightarrow \alpha_2 = 2.5.$$

$$\text{Assim, a função } \varphi(x) = \alpha_1 e^{-\alpha_2 x} = 3.001 e^{-2.5x}.$$



# CASO NÃO LINEAR

- Assim como no exemplo anterior onde ajustamos uma exponencial com expoente negativo, podemos linearizar algumas situações comuns

1) Uma hipérbole:  $y \approx \frac{1}{\alpha_1 + \alpha_2 x} = \varphi(x)$   
( $z = \frac{1}{y} \approx \alpha_1 + \alpha_2 x$ ).

2) Uma curva exponencial:  $y \approx \alpha_1 \alpha_2^x = \varphi(x)$

(se  $y > 0$ ,  $z = \ln(y) \approx \underbrace{\ln(\alpha_1)}_{a_1} + x \underbrace{\ln(\alpha_2)}_{a_2} = a_1 + a_2 x = \phi(x)$ ).

# CASO NÃO LINEAR

3) Uma curva geométrica:  $y \approx \alpha_1 x^{\alpha_2} = \varphi(x)$

$$(se\ x > 0\ e\ y > 0, z = \ln(y) \approx \underbrace{\ln(\alpha_1)}_{a_1} + \underbrace{\alpha_2}_{a_2} \underbrace{\ln(x)}_t = a_1 + a_2 t)$$


$\Rightarrow z = \ln(y) \approx a_1 + a_2 t = \phi(t)$ . (Aqui minimizamos a soma dos quadrados dos desvios nos logaritmos de y, para os logaritmos de x.)

4) Uma curva trigonométrica:  $y \approx \alpha_1 + \alpha_2 \cos(wx) = \varphi(x)$ . ( $t = \cos(wx) \Rightarrow \varphi(t) = \alpha_1 + \alpha_2 t$  e, neste caso, estamos minimizando a soma dos quadrados dos desvios em y.)

# CASO NÃO LINEAR

- Para fazer o teste de alinhamento da solução é possível plotar um gráfico para analisar o ajuste visualmente

- Exemplo



# EXERCÍCIO

- Gerar 3 conjunto de dados (X e Y) com modelos diferentes (contendo pelo menos 1 polinomial e 1 não polinomial)
- Ajustar uma função que intuitivamente melhor descreve cada conjunto de dados gerados
  - Utilize um ajuste linear e um ajuste não linear para cada um dos 3 conjuntos
- Plote o gráfico com os dados e a curva ajustada